ASSOCIATION RULE MINING

Nama: Rafa Rizki Aira Swala
NRP: 5054251017
Dataset: Online Retail

1. Pendahuluan

Praktikum ini menerapkan algoritma Apriori pada dataset Online Retail dari UCI Machine Learning Repository yaitu transaksi ritel online toko di Inggris periode Desember 2010 – Desember 2011 dengan total 541.909 baris dan 8 kolom. Tujuan praktikum: memahami konsep Association Rule, mengekstraksi aturan asosiasi dengan Apriori, dan mengevaluasinya dengan support, confidence, serta lift.

2. Eksplorasi dan Pembersihan Data

2.1 Struktur Dataset Awal

Dataset terdiri dari 541.909 baris dan 8 kolom: InvoiceNo, StockCode, Description, Quantity, InvoiceDate, UnitPrice, CustomerID, dan Country. Dari eksplorasi awal, dataset memiliki 25.900 invoice unik. Namun ditemukan beberapa karakteristik data yang perlu dibersihkan sebelum analisis: sebanyak 1.454 baris memiliki Description kosong, 9.288 transaksi merupakan pembatalan (InvoiceNo diawali huruf 'C'), dan 10.624 baris memiliki Quantity bernilai nol atau negatif. Ketiga kondisi ini perlu ditangani agar analisis Association Rule hanya menggunakan transaksi pembelian yang valid.

2.2 Langkah Pembersihan Data

- Hapus baris dengan Description kosong
- Hapus transaksi dibatalkan (InvoiceNo diawali 'C')
- Hapus baris dengan Quantity ≤ 0
- Normalisasi Description

3. Persiapan Data untuk Association Rule

3.1 Format Transaksi Berbasis Invoice

Data ditransformasi menjadi format transaksi: setiap InvoiceNo berisi list produk unik yang dibeli dalam satu transaksi. Hasil transformasi:

- Jumlah transaksi (invoice) unik : 20,136
- Rata-rata item per transaksi : 25.82
- Maksimum item per transaksi : 1108

3.2 One-Hot Encoding

Data transaksi kemudian diubah ke bentuk one-hot encoding menggunakan mlxtend.preprocessing.TransactionEncoder, menghasilkan matriks basket berukuran invoice × produk dengan nilai boolean (True = produk dibeli di invoice tersebut).

- Shape basket (invoice x produk): (20136, 4065)
- Jumlah produk unik : 4,065
- Sparsity basket : 99.36%

Sparsity tinggi (>95%) normal dalam market basket analysis dan menjadi alasan mengapa minimum support sangat penting sebagai filter dan tanpa threshold, algoritma akan dipaksa mengevaluasi miliaran kombinasi yang jarang muncul.

4. Penerapan Algoritma Apriori

4.1 Parameter Awal

Parameter	**Nilai**
min_support	0.01
min_confidence	0.5
max_len itemset	3
Filter lift > 1	Wajib

4.2 Hasil Frequent Itemset

Algoritma Apriori berhasil menemukan frequent itemset dengan support ≥ 1%. Distribusi itemset berdasarkan panjang:

- 1 item = 803
- 2 item = 818
- 3 item = 215

Top 5 frequent itemset dengan support tertinggi:

	Itemset	Support (%)
0	WHITE HANGING HEART T-LIGHT HOLDER	11.22
1	JUMBO BAG RED RETROSPOT	10.39
2	REGENCY CAKESTAND 3 TIER	9.88
3	PARTY BUNTING	8.37
4	LUNCH BAG RED RETROSPOT	7.77
5	ASSORTED COLOUR BIRD ORNAMENT	7.23

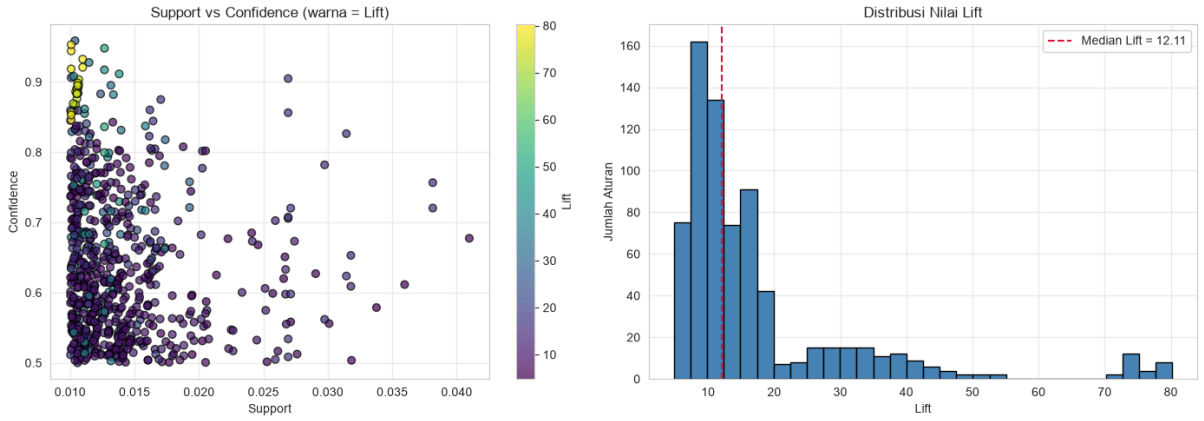
4.3 Hasil Association Rules

Setelah filter lift > 1 dan confidence ≥ 0.5, dihasilkan [isi dari cell 26] aturan asosiasi yang siap dievaluasi.

5. Evaluasi Aturan Asosiasi

5.1 Tiga Aturan Terbaik Berdasarkan Lift

	Jika Membeli	Maka Membeli	Support	Confidence	Lift
0	HERB MARKER PARSLEY, HERB MARKER ROSEMARY	HERB MARKER THYME	0.0101	0.9442	80.220
1	HERB MARKER THYME	HERB MARKER PARSLEY, HERB MARKER ROSEMARY	0.0101	0.8565	80.220
2	HERB MARKER ROSEMARY	HERB MARKER PARSLEY, HERB MARKER THYME	0.0101	0.8458	79.961



5.2 Interpretasi Bisnis

Aturan 1: Jika membeli HERB MARKER PARSLEY + HERB MARKER ROSEMARY, maka membeli HERB MARKER THYME (support = 0.0101, confidence = 0.9442, lift = 80.220).

Interpretasi: Pelanggan yang membeli penanda herbal Parsley dan Rosemary memiliki peluang 80 kali lebih besar untuk membeli penanda Thyme dibanding pelanggan biasa. Nilai confidence 94,42% menunjukkan hampir seluruh pelanggan yang membeli dua varian tersebut juga membeli varian ketiga. Pola ini mengindikasikan bahwa ketiga produk merupakan satu set koleksi dan pelanggan merasa "kurang lengkap" jika hanya membeli sebagian.

Rekomendasi: Tawarkan bundling set lengkap 3 varian (Parsley + Rosemary + Thyme) dengan harga khusus. Tampilkan ketiga varian berdampingan di halaman produk agar pelanggan mudah melengkapi koleksinya.

Aturan 2: Jika membeli HERB MARKER THYME, maka membeli HERB MARKER PARSLEY + HERB MARKER ROSEMARY (support = 0.0101, confidence = 0.8565, lift = 80.220).

Interpretasi: Thyme berfungsi sebagai entry product — pelanggan yang membeli satu varian cenderung melengkapi koleksinya dengan dua varian lainnya. Confidence sedikit lebih rendah (85,65%) karena ada sebagian pelanggan yang hanya membeli Thyme tanpa melengkapi. Ini pola klasik "starter product → full collection" yang umum pada produk koleksi.

Rekomendasi: Saat pelanggan membeli Thyme, tampilkan rekomendasi "Lengkapi koleksi Anda" dengan menawarkan Parsley + Rosemary sebagai paket tambahan. Gunakan Thyme sebagai trigger upsell untuk set lengkap.

Aturan 3: Jika membeli HERB MARKER ROSEMARY, maka membeli HERB MARKER PARSLEY + HERB MARKER THYME (support = 0.0101, confidence = 0.8458, lift = 79.961).

Interpretasi: Rosemary juga berfungsi sebagai entry product ke koleksi Herb Marker, mengonfirmasi bahwa ketiga varian membentuk satu set yang saling melengkapi. Pembelian satu varian memicu keinginan untuk melengkapi varian lainnya.

Rekomendasi: Perlakukan ketiga varian sebagai satu unit marketing. Jangan dijual terpisah dalam kampanye utama, tetapi tawarkan sebagai set. Kirim email follow-up dengan promo "Lengkapi set Anda" ke pelanggan yang baru membeli satu varian.

6. Analisis dan Rekomendasi Bisnis

6.1 Temuan Utama

- Pola asosiasi terkuat dalam dataset bukan berasal dari produk paling populer, melainkan dari klaster produk koleksi seperti set HERB MARKER (Parsley, Rosemary, Thyme). Produk dengan support tinggi seperti WHITE HANGING HEART T-LIGHT HOLDER (11,22%) dan JUMBO BAG RED RETROSPOT (10,39%) justru tidak membentuk asosiasi kuat karena dibeli oleh banyak pelanggan berbeda dengan alasan berbeda.

- Aturan dengan lift tinggi (>79) menunjukkan asosiasi produk yang saling melengkapi dalam satu set koleksi, bukan sekadar kebetulan statistik. Ini sangat valuable untuk sistem rekomendasi produk — lift tinggi menandakan pelanggan yang membeli satu varian hampir pasti akan melengkapi koleksinya.

- Support rendah (1%) pada aturan terbaik menunjukkan bahwa pola terkuat bersifat niche — pembelinya sedikit, tetapi sangat loyal dan konsisten. Ini peluang untuk strategi marketing targeted, bukan kampanye massal.

6.2 Rekomendasi Bisnis

- Cross-selling: Tampilkan consequent sebagai rekomendasi saat pelanggan melihat antecedent di halaman produk. Untuk koleksi Herb Marker, tampilkan ketiga varian berdampingan.

- Bundling: Buat paket diskon untuk pasangan produk dengan lift tinggi, misalnya "Set Lengkap Herb Marker" (Parsley + Rosemary + Thyme).
- Store layout: Kelompokkan produk berasosiasi dalam satu kategori visual, misalnya kategori "Herb Marker Collection" agar pelanggan mudah menemukan semua varian.
- Targeted promo: Kirim voucher produk consequent ke pelanggan yang sudah membeli antecedent. Untuk pelanggan yang membeli satu varian Herb Marker, kirim email follow-up dengan promo "Lengkapi set Anda".

7. Kesimpulan

Berdasarkan hasil analisis Association Rule Mining menggunakan algoritma Apriori pada dataset Online Retail, dapat disimpulkan:

A. Algoritma Apriori berhasil mengekstraksi pola asosiasi bermakna dari dataset Online Retail, tetapi memerlukan pembersihan data terlebih dahulu untuk menghindari noise dari retur dan transaksi tidak valid.

B. Metrik evaluasi saling melengkapi — support mengukur popularitas, confidence mengukur keandalan prediksi, dan lift mengukur kekuatan asosiasi relatif terhadap random chance. Lift adalah metrik terpenting untuk menemukan asosiasi truly actionable, karena confidence tinggi tidak selalu berarti asosiasi kuat. Pada dataset ini, produk paling populer justru tidak membentuk asosiasi kuat — yang berasosiasi kuat adalah produk niche yang dibeli sebagai koleksi.

C. Tuning parameter sangat krusial — min_support terlalu rendah menghasilkan eksplosif itemset, terlalu tinggi menghilangkan pola penting. Nilai 0.01 adalah sweet spot untuk dataset sebesar ini karena cukup menangkap pola niche (seperti Herb Marker dengan support 1%) tanpa menghasilkan itemset yang terlalu banyak.

D. Hasil analisis dapat langsung diaplikasikan ke sistem rekomendasi produk, bundling promo, dan strategi merchandising ritel — memberikan nilai bisnis nyata bagi toko online, khususnya untuk produk koleksi yang memiliki pelanggan loyal.