Preprocessing Dataset House Prices - Advanced Regression Techniques

Nama: Rafa Rizki Aira Swala
NRP: 5054251017

1. Deskripsi Dataset

Dataset diperoleh dari kompetisi Kaggle House Prices - Advanced Regression Techniques. Data berisi informasi penjualan rumah di Ames, Iowa, dengan atribut seperti ukuran tanah, tahun dibangun, kualitas rumah, dan sebagainya. File yang digunakan hanya train.csv (1.460 baris × 81 kolom).

Kolom	Tipe	Keterangan
Id	Nominal	ID unik rumah
AuthorMSSubClass, MSZoning, LotArea, ...	Campuran	79 atribut penjelas (numerik & kategorikal)
SalePrice	Numerik	Harga jual rumah (target)

Catatan: 38 kolom numerik, 43 kolom kategorikal. Terdapat nilai hilang pada 19 kolom.

2. Statistik Deskriptif

2.1 Nilai Hilang

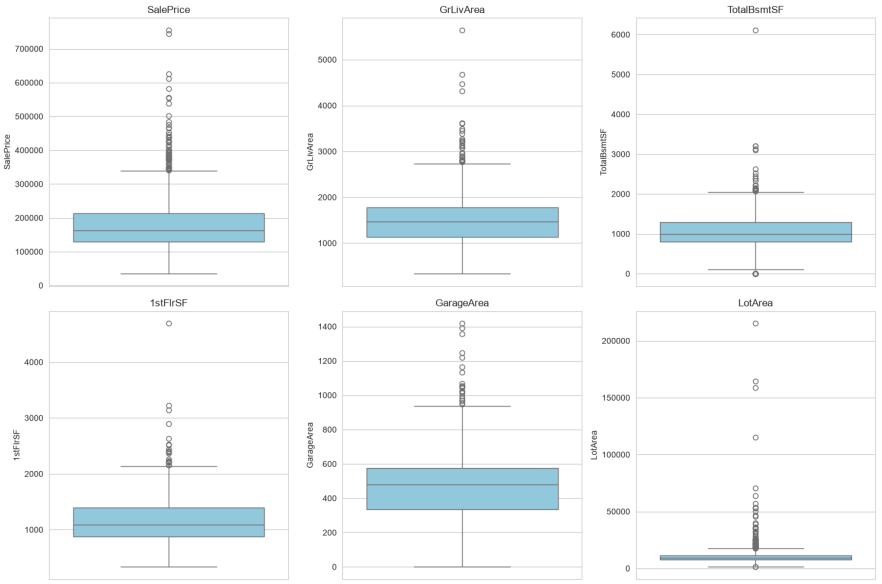
Ditemukan 19 kolom dengan nilai hilang. Kolom dengan proporsi > 50% dihapus karena informasinya terlalu sedikit untuk diimputasi:

Kolom	Missing	Persentase
PoolQC	1.453	99,52%
MiscFeature	1.406	96,30%
Alley	1.369	93,77%
Fence	1.179	80,75%
MasVnrType	872	59,73%

5 kolom dihapus → shape menjadi (1460, 76).
Sisa nilai hilang ditangani:
Numerik diisi median dan kategorikal diisi modus
Setelah imputasi: total missing = 0.

3. Deteksi dan Penanganan Outlier

Deteksi outlier menggunakan boxplot pada 6 atribut numerik utama (SalePrice, GrLivArea, TotalBsmtSF, 1stFlrSF, GarageArea, LotArea).



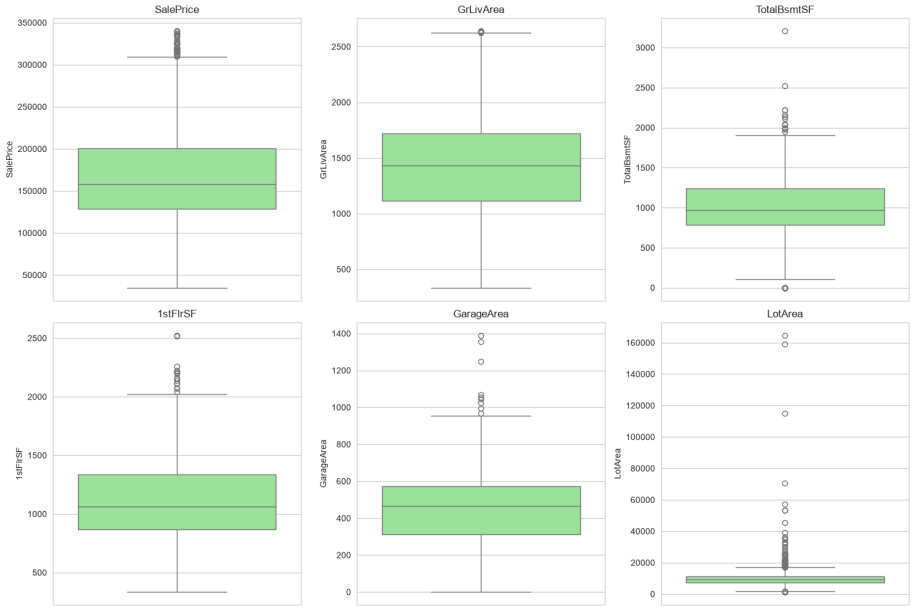
Gambar 1 — Boxplot sebelum penanganan outlier

Metode penanganan: IQR (Interquartile Range)
Alasan: robust, terukur, dan tidak memodifikasi nilai data seperti capping.

Outlier dihapus hanya pada SalePrice dan GrLivArea (paling berpengaruh ke model regresi):

Atribut	Outlier Dihapus
SalePrice	61
GrLivArea	21
Total Baris	82

Shape setelah outlier removal: (1378, 76)



Gambar 2 — Boxplot setelah penanganan outlier

4. Transformasi Data

4.1 One-Hot Encoding

Kolom kategorikal diubah menjadi numerik dengan pd.get_dummies(drop_first=True).

Tahap	Shape
Sebelum encoding	(1378, 75)
Setelah encoding	(1378, 231)

Menghasilkan 156 kolom baru.

4.2 Standarisasi

Menggunakan StandardScaler (mean = 0, std = 1) agar skala antar fitur seragam — penting untuk PCA dan algoritma berbasis jarak.

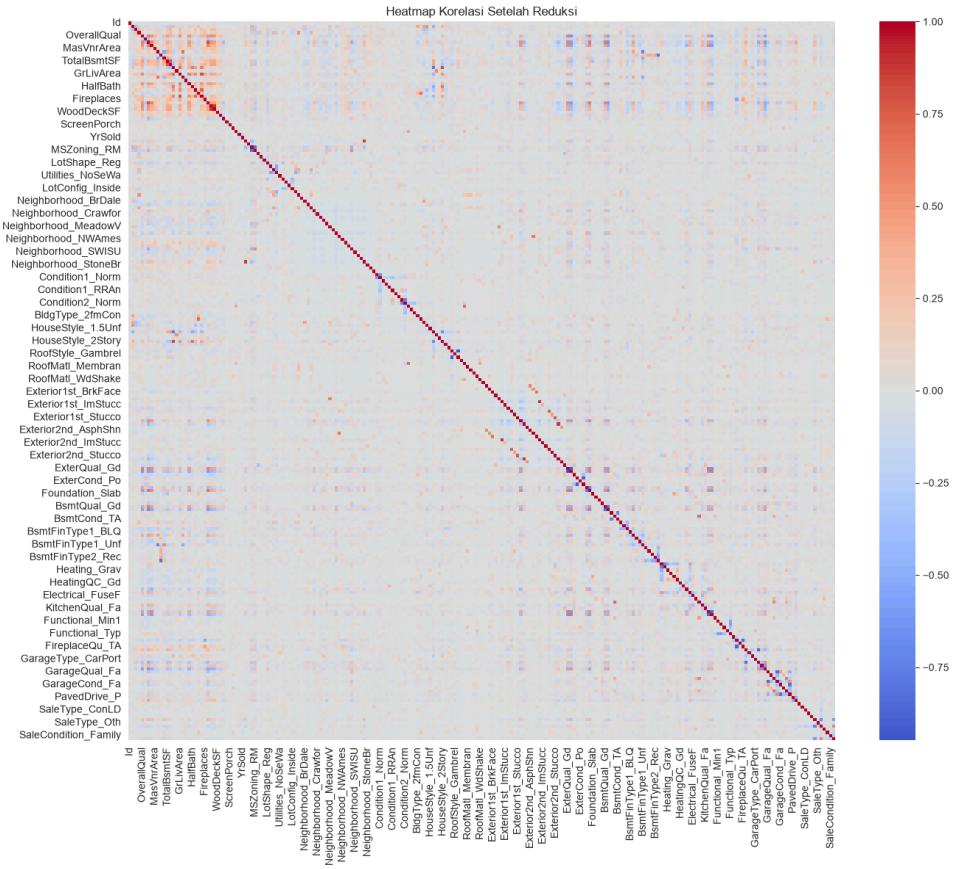
Shape tetap: (1378, 231).

5. Reduksi Dimensi

5.1 Analisis Korelasi

Kolom dengan korelasi > 0.95 dianggap redundan dan salah satunya dibuang. Ditemukan 5 kolom yaitu Exterior2nd_CBlock, Exterior2nd_CmentBd, Exterior2nd_MetalSd, Exterior2nd_VinylSd', dan 'SaleCondition_Partial.

Shape setelah reduksi korelasi: (1378, 226)



Gambar 3 — Heatmap korelasi

5.2 PCA (Principal Component Analysis)

PCA diterapkan dengan n_components=0.95 untuk mempertahankan 95% variansi.

Parameter	Nilai
Komponen awal	226
Komponen setelah PCA	155

Reduksi dimensi	31,4%
Variansi dipertahankan	95,06%

6. Ringkasan Dataset Akhir

Tahapan	Baris	Kolom
Dataset awal	1460	81
Hapus kolom missing > 50%	1460	76
Imputasi missing	1460	76
Outlier removal	1378	76
One-hot encoding	1378	231
Reduksi korelasi	1378	226
PCA (final)	1378	156

- 1378 baris × 156 kolom (155 komponen PCA + SalePrice)
- 0 missing values
- Outlier utama sudah dihilangkan
- Semua fitur terstandarisasi
- Variansi 95,06% dipertahankan

7. Kesimpulan

1. Pembersihan data berhasil menghapus 5 kolom dengan missing > 50% dan mengimputasi 14 kolom sisanya (median untuk numerik, modus untuk kategorikal) — total missing akhir = 0.
2. Outlier pada SalePrice dan GrLivArea dihapus menggunakan metode IQR (82 baris), menghasilkan distribusi data yang lebih bersih.
3. Transformasi data melalui one-hot encoding (75 → 231 kolom) dan standarisasi berhasil menyiapkan seluruh fitur agar siap diproses algoritma machine learning.
4. Reduksi dimensi via analisis korelasi (hapus 5 kolom redundan) dan PCA (226 → 155 komponen) mempertahankan 95,06% variansi sekaligus menurunkan dimensi 31%.
5. Dataset akhir berisi 1378 baris × 156 kolom, siap digunakan untuk tahap pemodelan.