Scrapping dan EDA Dataset Game Indie itch.io

Nama: Rafa Rizki Aira Swala
NRP: 5054251017

1. Deskripsi Dataset

Dataset diperoleh melalui scraping halaman browse itch.io (https://itch.io/games) menggunakan library requests dan BeautifulSoup. Pengambilan data dilakukan secara bertahap dengan delay acak 3–6 detik antar request untuk menghindari rate limit. Hasil scraping mentah disimpan sebagai itchio_games_v2.csv sebelum diolah lebih lanjut.

Dataset berisi 1.620 baris dan 5 kolom:

Kolom	Tipe	Keterangan
Title	Nominal	Judul game
Author	Nominal	Nama developer/pembuat
Genre	Nominal	Kategori game
Description	Nominal	Deskripsi singkat game
Price	Numerik	Harga dalam USD; 0 = gratis

Catatani: Game dengan skema "name your own price" diklasifikasikan sebagai gratis (harga = 0) karena tidak memiliki harga minimum tetap. Kolom rating yang semula direncanakan dihapus karena tidak tersedia di halaman browse itch.io. Temuan ini sendiri merupakan insight bahwa mayoritas game indie tidak menampilkan rating publik.

2. Statistik Deskriptif

Atribut numerik seluruh dataset:

Statistik	Nilai
Mean	0.99
Median	0.0
Modus	0.0
Std Dev	3.67
Min	0.0
Max	30.0

Atribut numerik hanya game berbayar:

Statistik	Nilai
Jumlah game	173 (10,7%)
Mean	0.99
Median	0.0
Min	0.0
Max	30.0

Atribut kategorikal:
- Genre terbanyak: Visual Novel, Adventure, Simulation.
- Genre paling sedikit: Racing, Rhythm, Fighting.
- Author paling produktif: NomnomNami, ebi-hime, Honey Bunny.

Rata-rata harga seluruh game adalah $0,99, namun median dan modus bernilai $0. Perbedaan ini menandakan distribusi harga yang sangat miring ke kanan (right-skewed). Dari 1.620 game, sebanyak 1.447 game (89,3%) gratis dan hanya 173 game (10,7%) yang berbayar. Jika analisis dibatasi pada game berbayar saja, rata-rata harganya melonjak menjadi $9,31 dengan median $6,99.

Artinya, angka mean $0,99 pada keseluruhan dataset menyesatkan jika dibaca tanpa konteks — mayoritas game memang gratis, tetapi game yang berbayar dijual dengan harga yang cukup signifikan. Ini contoh klasik mengapa median dan modus harus dilaporkan bersama mean.

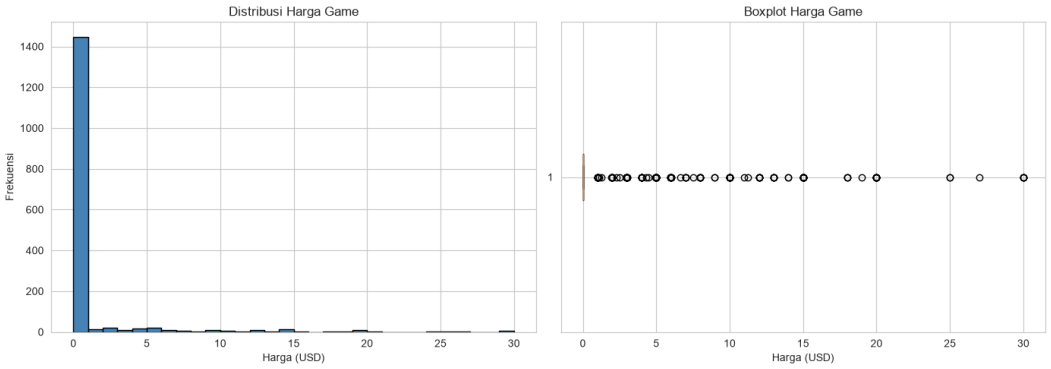
3. Penanganan Data

Nilai hilang:
- Kolom description memiliki 91 nilai kosong (5.62%).
- Kolom lain tidak memiliki nilai hilang.
- Penanganan: Nilai kosong pada description dibiarkan (tidak diimputasi) karena kolom ini bersifat opsional dan tidak digunakan dalam analisis statistik utama.

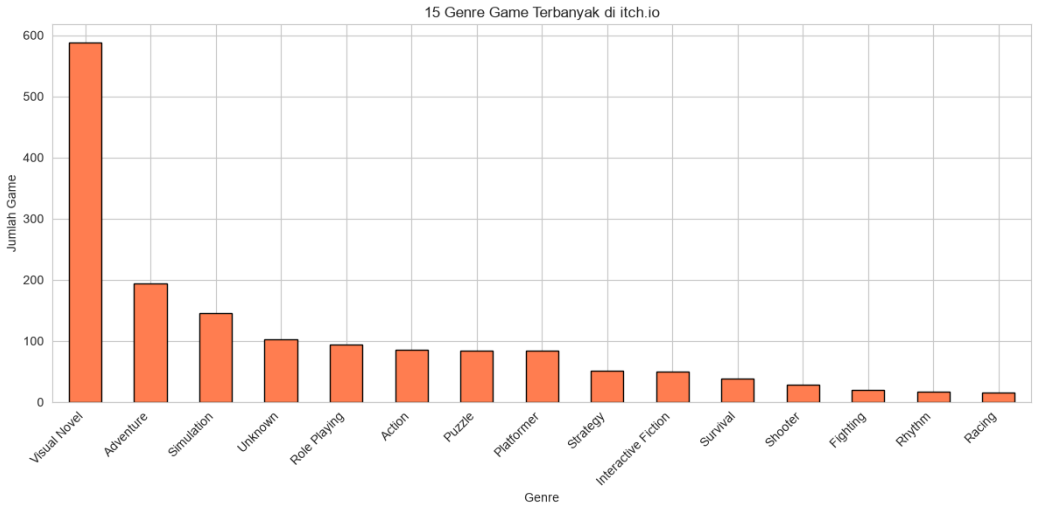
Outlier:
- Deteksi outlier menggunakan metode IQR pada kolom price.
- Ditemukan 173 outlier harga di atas rata-rata yaitu 0

4. Visualisasi & Interpretasi

A. Univariat

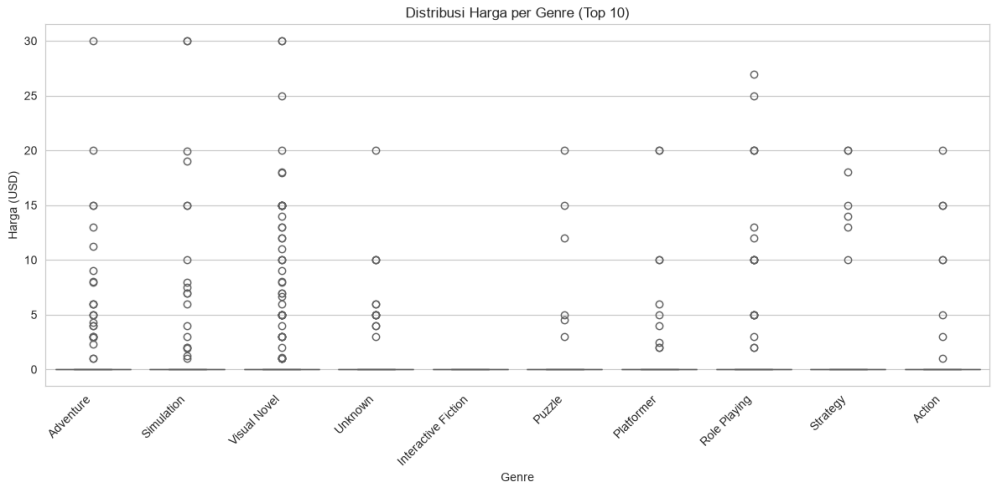


Histogram harga menunjukkan lonjakan besar di titik $0, mengonfirmasi dominasi game gratis di itch.io (89,3%). Distribusi game berbayar membentang dari sekitar $1 hingga maksimum $30, dengan konsentrasi di rentang $5–$10. Boxplot menunjukkan banyak outlier di sisi atas, yaitu game-game premium dengan harga jauh di atas mayoritas. Bentuk distribusi ini mencerminkan strategi pricing developer indie yaitu mayoritas memilih gratis untuk menjangkau audiens, sementara yang berbayar menetapkan harga di bawah $10 agar tetap kompetitif.

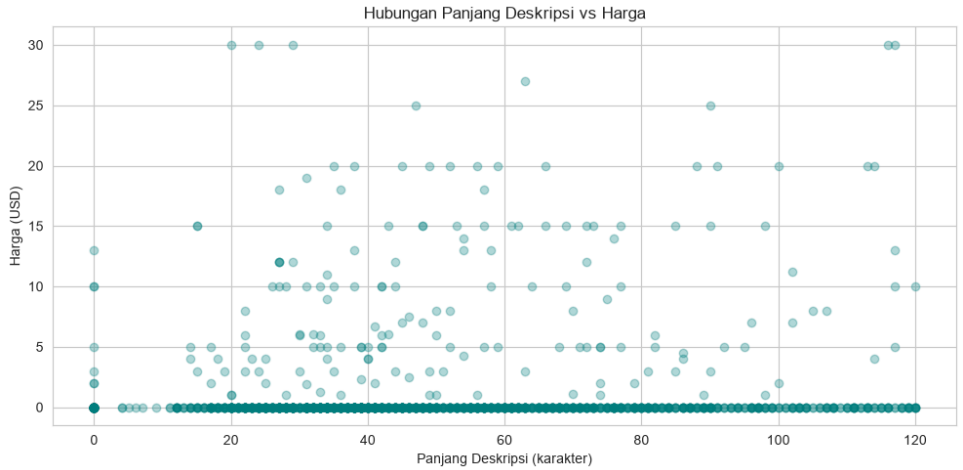


Genre Visual Novel Adventure, dan Simulation mendominasi itch.io. Ini menunjukkan preferensi komunitas itch.io terhadap game naratif dan kasual dibanding genre kompetitif seperti Action atau Shooter.

B. Bivariat



Genre Visual Novel cenderung memiliki harga lebih tinggi, sementara Puzzle paling murah. Genre dengan box lebih pendek menunjukkan konsistensi harga yang lebih tinggi. Ini mengindikasikan bahwa nilai produksi dan ekspektasi audiens berbeda-beda antar genre.



Tidak ada korelasi signifikan antara panjang deskripsi dan harga. Artinya, developer game mahal tidak selalu menulis deskripsi lebih detail. Kualitas deskripsi tidak bisa dijadikan proxy untuk harga.

5. Kesimpulan

Dari eksplorasi dataset 1.620 game indie di itch.io, dapat disimpulkan:

- Rata-rata harga seluruh game adalah $0,99, tetapi median dan modus bernilai $0. Perbedaan ini terjadi karena 89,3% game gratis. Jika hanya melihat game berbayar, rata-rata harganya adalah $9,31 dengan median $6,99 angka yang jauh lebih realistis.
- Platform ini berfungsi sebagai ruang eksperimen gratis bagi developer pemula (89,3% game gratis), sekaligus pasar komersial bagi game indie serius dengan harga terjangkau ($5–$10).

- Visual Novel menjadi kategori paling populer, menunjukkan preferensi komunitas itch.io terhadap game bercerita dibanding genre kompetitif.
- Nilai hilang hanya ditemukan pada description (5.62%), sementara outlier harga dibiarkan karena valid secara bisnis dan justru informatif.
- Tidak tersedianya rating di halaman browse membuat analisis kualitas game tidak dapat dilakukan. Penelitian lanjutan disarankan untuk scraping halaman detail game guna mendapatkan rating dan jumlah unduhan.