SEQUENTIAL PATTERN ANALYSIS

Nama: Rafa Rizki Aira Swala
NRP: 5054251017
Dataset: Online Retail

1. Pendahuluan

Praktikum ini menerapkan algoritma PrefixSpan pada dataset Online Retail dari UCI Machine Learning Repository, yaitu transaksi ritel online toko di Inggris periode Desember 2010 – Desember 2011 dengan total 541.909 baris dan 8 kolom. Berbeda dengan Association Rule yang mencari asosiasi dalam satu transaksi, Sequential Pattern Analysis mencari pola pembelian berurutan antar waktu untuk setiap pelanggan.

Tujuan praktikum: memahami konsep Sequential Pattern, mengekstraksi pola berurutan dengan PrefixSpan, serta mengevaluasinya menggunakan support dan confidence.

2. Eksplorasi dan Pembersihan Data

2.1 Struktur Dataset Awal

Dataset terdiri dari 541.909 baris dan 8 kolom: InvoiceNo, StockCode, Description, Quantity, InvoiceDate, UnitPrice, CustomerID, dan Country. Eksplorasi awal menemukan 25.900 invoice unik, 4.372 pelanggan unik, dan 4.070 produk unik (StockCode). Ditemukan karakteristik data yang perlu dibersihkan sebelum analisis: 1.454 baris memiliki Description kosong, 9.288 transaksi merupakan pembatalan (InvoiceNo diawali 'C'), 10.624 baris memiliki Quantity ≤ 0, dan 135.080 baris memiliki CustomerID kosong.

2.2 Langkah Pembersihan Data

Pembersihan dilakukan dengan menghapus baris Description kosong, menghapus transaksi dibatalkan, menghapus baris dengan Quantity ≤ 0, dan menghapus baris dengan CustomerID kosong. Setelah pembersihan, dataset menyusut dari 541.909 baris menjadi 397.924 baris, dengan 18.536 invoice unik dan 4.339 pelanggan unik.

3. Persiapan Data untuk Association Rule

3.1 Pembentukan Sequence per Pelanggan

Data diurutkan berdasarkan CustomerID dan InvoiceDate, lalu item dalam satu invoice dikelompokkan menjadi satu itemset. Setiap pelanggan direpresentasikan sebagai satu sequence berisi daftar itemset yang terurut secara waktu. Dari proses ini diperoleh 4.339 sequence dengan rata-rata 4,28 itemset per pelanggan, median 2 itemset, dan maksimum 211 itemset.

Distribusi jumlah itemset per pelanggan sangat right-skewed: 1.492 pelanggan (34%) hanya memiliki 1 itemset, dan mayoritas (lebih dari 70%) memiliki ≤ 5 itemset. Hanya sebagian kecil pelanggan yang memiliki puluhan hingga ratusan itemset.

3.2 Flatten dan Filter Noise

Library prefixspan membutuhkan item hashable (string), bukan itemset berbentuk list. Karena itu, itemset di-flatten menjadi urutan produk individual. Selain itu, item administratif yang bukan produk nyata (Manual, POSTAGE, DOTCOM POSTAGE, Bank Charges, Discount, dan sejenisnya) difilter agar pola mencerminkan perilaku pembelian produk.

Setelah filter, sequence yang tersisa minimal 2 item: 4.261 pelanggan. Rata-rata item per sequence setelah flatten adalah 90,65 (median 41, maksimum 7.466).

4. Penerapan Algoritma PrefixSpan

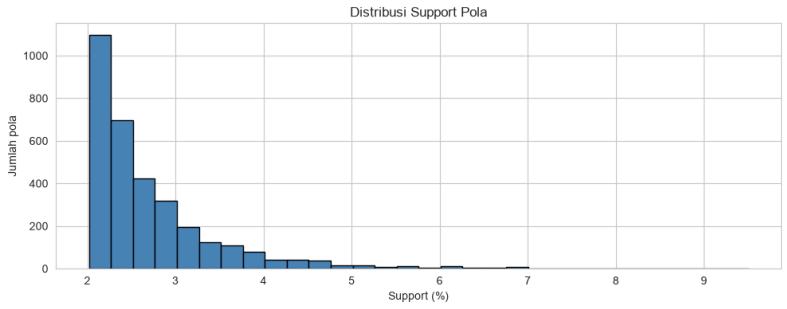
4.1 Penyesuaian Parameter

Nilai awal min_support = 0.01 dan max_len = 4 tidak feasible pada data ini. Data memiliki 3.866 produk unik (setelah pembersihan) dengan distribusi sangat sparse; item terpopuler (REGENCY CAKESTAND 3 TIER) muncul pada 878 pelanggan (20,61%), diikuti WHITE HANGING HEART T-LIGHT HOLDER (856, 20,09%), dan PARTY BUNTING (706, 16,57%). Setelah item terpopuler, jumlah pelanggan per produk turun tajam.

Nilai max_len = 4 menyebabkan ledakan kandidat — eksekusi tidak selesai setelah 14 menit. Nilai min_support = 1% menghasilkan lebih dari 5.000 pola, terlalu banyak untuk interpretasi. Parameter akhir yang dipilih: min_support = 0.02 (~86 pelanggan) dan max_len = 2. Nilai ini cukup menangkap pola bermakna tanpa menghasilkan ribuan pola yang tidak actionable.

4.2 Hasil Frequent Sequence

Dengan min_support = 2% dan max_len = 2, PrefixSpan menghasilkan 3.244 pola berurutan, di mana 3.108 merupakan pola cross-product (bukan self-loop A → A). Self-loop (pembelian produk yang sama dua kali) tetap valid secara teknis tetapi kurang actionable untuk cross-selling.



5. Evaluasi Pola Berurutan

5.1 Tiga Pola Terbaik Berdasarkan Support

Pola pertama adalah PAPER CHAIN KIT 50'S CHRISTMAS → PAPER CHAIN KIT VINTAGE CHRISTMAS dengan support 7,53% (321 pelanggan) dan confidence 52,45%.

Pola kedua adalah GREEN REGENCY TEACUP AND SAUCER → ROSES REGENCY TEACUP AND SAUCER dengan support 7,46% (318 pelanggan) dan confidence 82,17%.

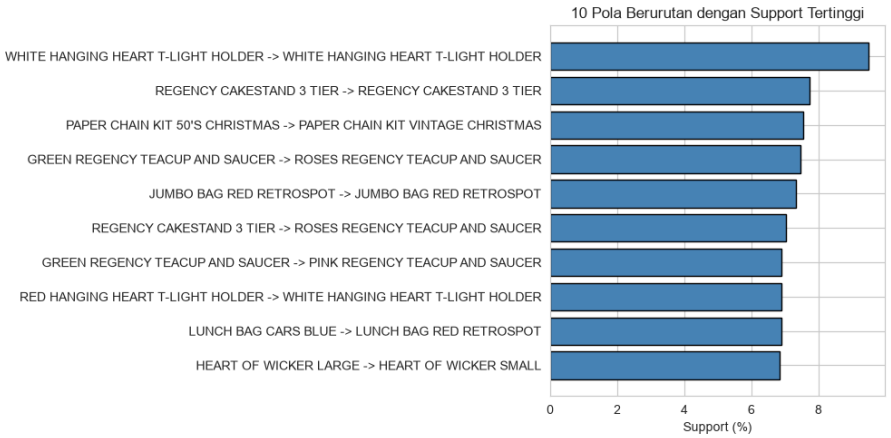
Pola ketiga adalah REGENCY CAKESTAND 3 TIER → ROSES REGENCY TEACUP AND SAUCER dengan support 7,02% (299 pelanggan) dan confidence 34,05%.

5.2 Tiga Pola Terbaik Berdasarkan Confidence

Pola pertama adalah SET/6 RED SPOTTY PAPER CUPS → SET/6 RED SPOTTY PAPER PLATES dengan support 3,52% (150 pelanggan) dan confidence 89,82%.

Pola kedua adalah CANDLEHOLDER PINK HANGING HEART → WHITE HANGING HEART T-LIGHT HOLDER dengan support 4,67% (199 pelanggan) dan confidence 89,64%.

Pola ketiga adalah REGENCY TEA PLATE PINK → REGENCY TEA PLATE ROSES dengan support 3,33% (142 pelanggan) dan confidence 88,75%.



5.3 Interpretasi Bisnis

Pola PAPER CHAIN KIT 50'S CHRISTMAS → PAPER CHAIN KIT VINTAGE CHRISTMAS (support 7,53%, confidence 52,45%). Pelanggan yang membeli paper chain kit tema Natal 50-an cenderung membeli varian vintage pada kesempatan berikutnya. Ini menunjukkan perilaku mengumpulkan varian tema (seasonal collection). Rekomendasi: tawarkan kedua varian sebagai paket "Christmas Paper Chain Bundle" di halaman produk.

Pola GREEN REGENCY TEACUP AND SAUCER → ROSES REGENCY TEACUP AND SAUCER (support 7,46%, confidence 82,17%). Confidence sangat tinggi: 8 dari 10 pembeli cangkir hijau Regency melanjutkan dengan varian Roses. Indikasi kuat pola koleksi set. Rekomendasi: tampilkan varian warna lain sebagai "Lengkapi koleksi Anda" saat pelanggan melihat satu varian Regency.

Pola SET/6 RED SPOTTY PAPER CUPS → SET/6 RED SPOTTY PAPER PLATES (support 3,52%, confidence 89,82%). Hampir 9 dari 10 pembeli paper cups langsung membeli paper plates set yang serasi. Ini pola party set lengkap. Rekomendasi: jual sebagai paket "Party Set Red Spotty" (cups + plates) dengan sedikit diskon untuk meningkatkan basket size.

5.3 Pola Umum yang Terdeteksi

Dari seluruh pola, dua tema dominan muncul berulang. Pertama, koleksi varian warna/desain pada lini Regency (teacup, tea plate, cakestand), hanging heart (pink/white), dan herb marker (chives/rosemary/thyme/parsley). Kedua, party/seasonal set seperti paper cups + plates dan paper chain kit tema Natal.

6. Analisis dan Rekomendasi Bisnis

6.1 Temuan Utama

Pola berurutan terkuat dalam dataset didominasi oleh produk koleksi dan set lengkap, bukan produk paling populer. Produk dengan support tinggi seperti WHITE HANGING HEART T-LIGHT HOLDER (support 9,50% sebagai pola self-loop) muncul sebagai pembelian ulang, bukan sebagai bagian dari pola cross-product yang kuat. Sebaliknya, lini produk seperti Regency dan Herb Marker menunjukkan asosiasi sangat kuat antar varian (confidence >80%), mengindikasikan pelanggan cenderung melengkapi koleksi.

Support absolut pola terbaik relatif kecil (3–7% pelanggan), tetapi confidence sangat tinggi (80–95%). Ini menunjukkan pola bersifat niche namun loyal — pembelinya sedikit tetapi sangat konsisten. Peluang terbaik untuk strategi targeted marketing, bukan kampanye massal.

6.2 Rekomendasi Bisnis

- Cross-selling berbasis varian: saat pelanggan melihat satu varian produk koleksi (Regency, Herb Marker, Hanging Heart), tampilkan varian warna/desain lain sebagai "Lengkapi koleksi Anda".
- Bundling: buat paket diskon untuk pola dengan confidence >80%, seperti "Party Set Red Spotty" (cups + plates) atau "Regency Tea Collection" (teacup + tea plate + cakestand).
- Seasonal Campaign: manfaatkan pola paper chain kit untuk kampanye pre-order Natal dengan penawaran bundle antar tema.

- Targeted promo: kirim voucher varian consequent ke pelanggan yang baru membeli antecedent, terutama untuk produk dengan confidence tinggi.

7. Kesimpulan

Pertama, algoritma PrefixSpan berhasil mengekstraksi pola pembelian berurutan bermakna dari dataset Online Retail, tetapi memerlukan pembersihan data dan transformasi sequence terlebih dahulu untuk menghindari noise dari retur, transaksi tidak valid, dan item administratif.

Kedua, penyesuaian parameter krusial pada data sparse. Dengan 3.866 produk unik dan support maksimum item tunggal hanya ~20,6%, min_support = 2% dan max_len = 2 dipilih agar pola yang dihasilkan wajar (3.108 cross-product) tanpa ledakan kandidat yang membuat eksekusi tidak feasible. Nilai max_len = 4 yang dicoba sebelumnya tidak selesai setelah 14 menit karena pertumbuhan kandidat eksponensial.

Ketiga, metrik support dan confidence saling melengkapi. Support mengukur seberapa banyak pelanggan yang menjalankan pola, sedangkan confidence mengukur keandalan prediksi. Pola dengan support rendah tetapi confidence tinggi (seperti Regency dan Herb Marker) justru paling actionable karena menunjukkan pelanggan yang sangat loyal terhadap koleksi.

Keempat, temuan utama adalah pola berurutan didominasi oleh (a) koleksi varian warna/desain dari lini produk yang sama, dan (b) pembelian set lengkap untuk keperluan pesta/seasonal. Pola ini langsung dapat diaplikasikan untuk sistem rekomendasi, bundling promo, dan strategi merchandising ritel.

Kelima, keterbatasan: mayoritas pelanggan (34%) hanya memiliki 1 itemset, sehingga sequence yang bisa dianalisis terbatas. Pembatasan max_len = 2 juga mengurangi kedalaman pola. Analisis lanjutan dapat mengelompokkan produk ke kategori untuk menemukan pola tingkat kategori yang lebih umum.