Classification dengan Ensemble Method & Class Imbalance

Nama: Rafa Rizki Aira Swala
NRP: 5054251017
Dataset: Credit Card Fraud Detection

1. Pendahuluan

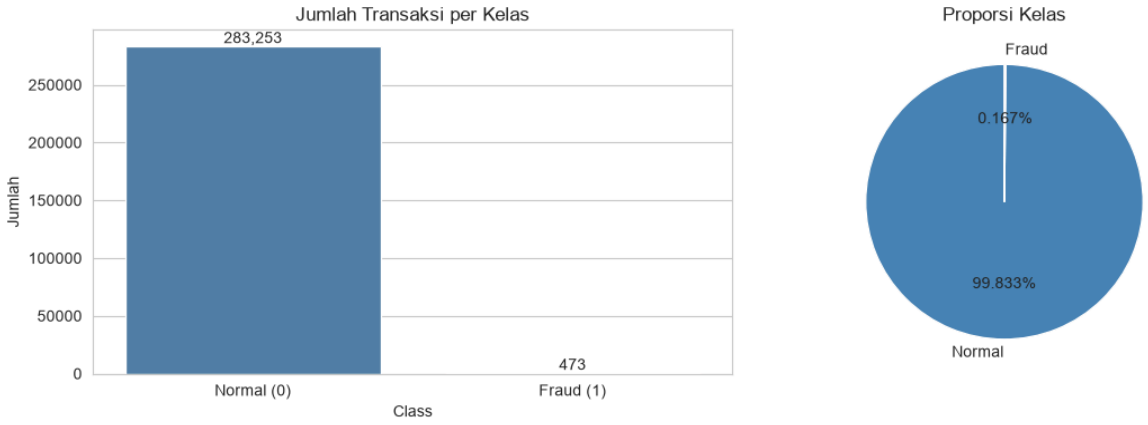
Credit Card Fraud Detection memiliki dua masalah yaitu distribusi kelas yang sangat tidak seimbang, dan konsekuensi bisnis dari kesalahan prediksi yang tidak simetris. Praktikum ini bertujuan membangun model klasifikasi menggunakan ensemble method (Random Forest dan Gradient Boosting) serta menerapkan teknik penanganan class imbalance berupa SMOTE.

2. Hasil Distribusi Kelas Awal

Dataset terdiri dari 284.807 transaksi dengan dua kelas:

- Normal (0): 283.253 transaksi (99,8333%)
- Fraud (1): 473 transaksi (0,1667%)

Rasio ketidakseimbangan mencapai 598,84 : 1 — artinya untuk setiap 1 transaksi fraud, terdapat hampir 600 transaksi normal.



Gambar 1: Bar chart dan pie chart distribusi kelas

Model yang selalu memprediksi "Normal" akan memperoleh accuracy ~99,83%, tetapi recall-nya 0% untuk kelas fraud. Kondisi ini menegaskan bahwa accuracy bukan metrik yang layak untuk dataset ini.

3. Pendekatan Penanganan Class Imbalance

3.1 Praproses Data

Tahap	Tindakan

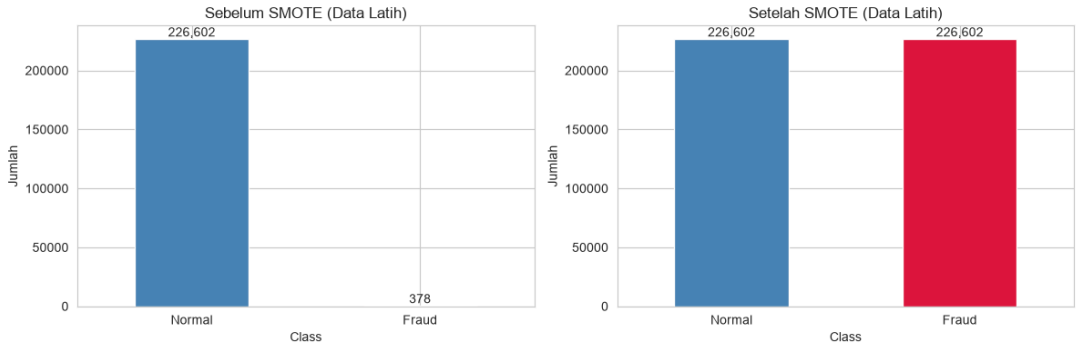
Duplikat	Baris duplikat dihapus
Missing Value	Dikonfirmasi bersih (0 missing)
Train-Test Split	80:20 dengan stratify=y
Scaling	StandardScaler pada kolom Time dan Amount

Stratifikasi memastikan proporsi kelas fraud di data latih (378 dari 226.980 = 0,1665%) dan data uji (95 dari 56.746 = 0,1674%) tetap mendekati distribusi asli.

3.2 SMOTE

SMOTE diterapkan hanya pada data latih. Data uji tetap memakai distribusi asli agar evaluasi mencerminkan kondisi dunia nyata.

Kondisi	**Normal**	**Fraud**	**Rasio**
Sebelum SMOTE	226.602	378	599,48 : 1
Setelah SMOTE	226.602	226.602	1 : 1



Gambar 2: Bar chart sebelum vs sesudah SMOTE

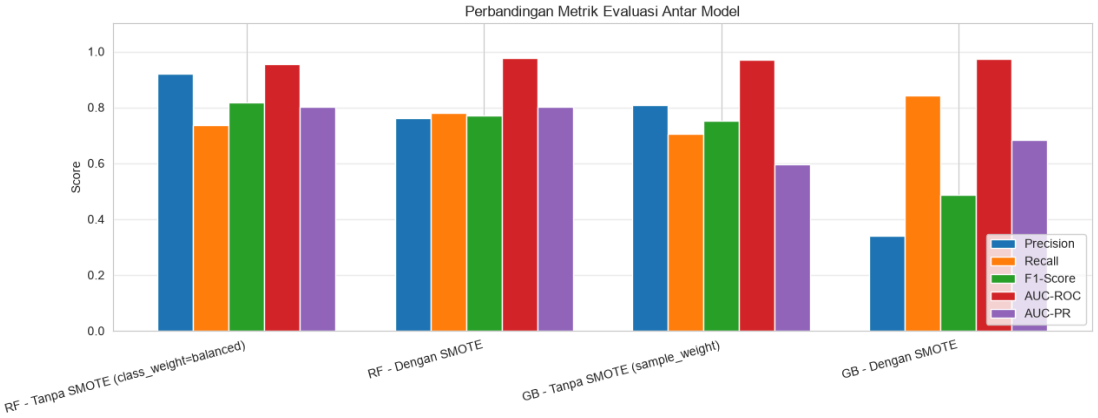
Alasan memilih SMOTE dibanding undersampling dikarenakan undersampling berisiko membuang informasi transaksi normal yang sebenarnya penting. SMOTE mempertahankan seluruh data asli sambil menambah sampel sintetis kelas minoritas.

4. Performa Model

4.1 Hasil Perbandingan

Model	**Precision**	**Recall**	**F1-Score**	**AUC-ROC**	**AUC-PR**
RF	0,9211	0,7368	0,8187	0,9559	0,8020
RF – SMOTE	0,7629	0,7789	0,7708	0,9771	0,8030

GB	0,8072	0,7053	0,7528	0,9690	0,5956
GB – SMOTE	0,3419	0,8421	0,4863	0,9742	0,6837



Gambar 3: Bar chart perbandingan metrik

4.2 Confusion Matriks

Model	**TN**	**FP**	**FN**	**TP**
RF	56.645	6	25	70
RF – SMOTE	56.628	23	21	74
GB	56.635	16	28	67
GB – SMOTE	56.497	154	15	80

4.3 Analisis Perbandingan

A. Dampak SMOTE terhadap Random Forest

Tanpa SMOTE, model sangat konservatif: hanya 6 false positive, tapi 25 fraud lolos (false negative). Dengan SMOTE, false positive naik ke 23 (+17), tapi fraud yang tertangkap naik dari 70 ke 74 (+4). Trade-off ini membuat AUC-ROC naik dari 0,9559 ke 0,9771. Ini peningkatan signifikan pada kemampuan model membedakan kelas secara umum.

B. Dampak SMOTE terhadap Gradient Boosting

GB menunjukkan pola ekstrem: dengan SMOTE, recall naik tajam ke 0,8421 (tertinggi di antara semua model, 80 dari 95 fraud tertangkap). Namun precision anjlok drastis ke 0,3419 — artinya ~66% prediksi fraud adalah false alarm (154 FP). Ini menandakan model terlalu agresif menebak fraud. F1-Score-nya jadi paling rendah (0,4863).

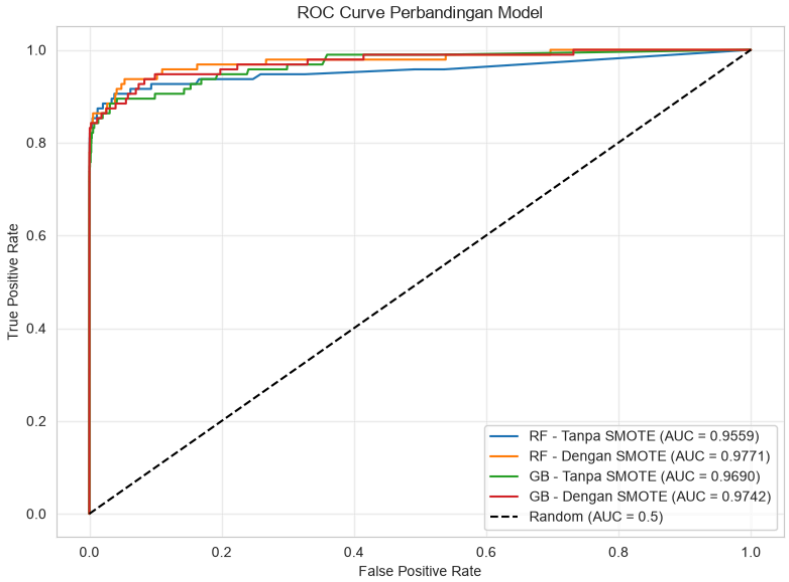
C. Random Forest vs Gradient Boosting

Aspek	Random Forest	Gradient Boosting
Waktu training	Cepat	Lambat
Stabilitas	Lebih stabil	Sensitif ke parameter
AUC-PR tanpa SMOTE	0,8020	0,5956
AUC-PR dengan SMOTE	0,8030	0,6837

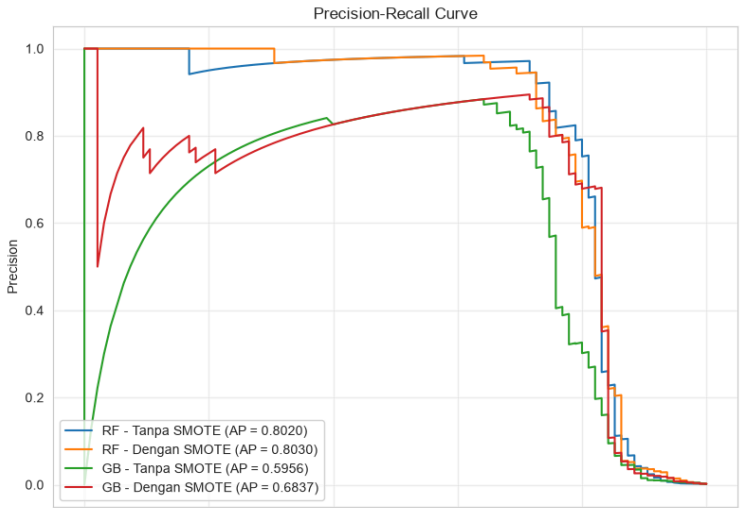
Random Forest menunjukkan performa yang lebih konsisten — baik dengan maupun tanpa SMOTE, F1-Score-nya selalu di atas 0,77. GB lebih fluktuatif: tanpa SMOTE AUC-PR-nya jeblok (0,5956), dengan SMOTE F1-nya jatuh (0,4863).

D. Model Terbaik

Berdasarkan kombinasi F1-Score (0,7708), AUC-ROC (0,9771), dan AUC-PR (0,8030), model terbaik secara keseluruhan adalah RF – Dengan SMOTE. Model ini memberikan keseimbangan terbaik antara menangkap fraud (74 dari 95) dan membatasi false alarm (23 dari 56.746 transaksi normal).



Gambar 4: ROC Curve semua model



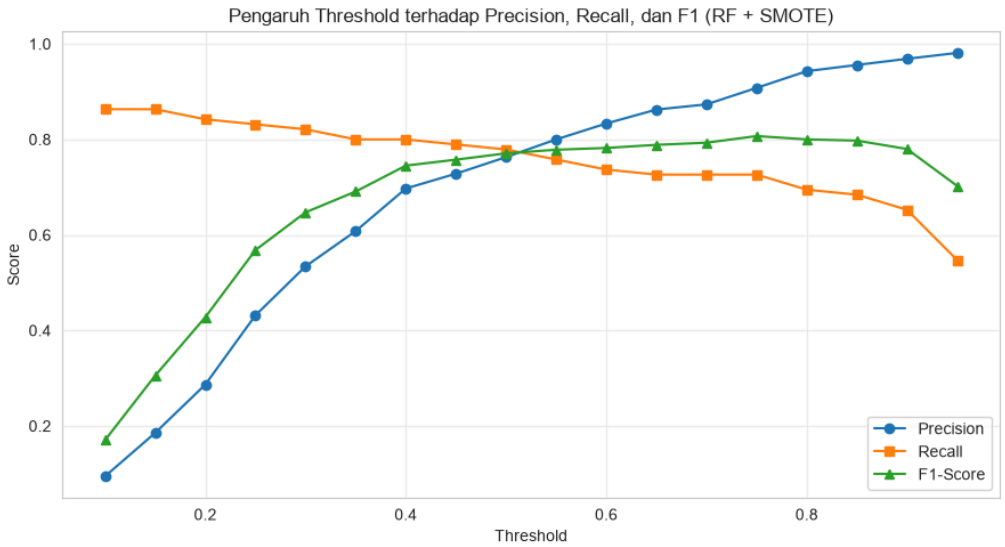
Gambar 5: Precision-Recall Curve semua model

5. Threshold Tuning

Karena threshold default 0,5 belum tentu optimal untuk fraud detection, dilakukan eksplorasi threshold pada model RF + SMOTE.

Threshold	Precision	Recall	F1-Score
0,40	0,6972	0,8000	0,7451
0,50	0,7629	0,7789	0,7708
0,60	0,8333	0,7368	0,7821
0,75	0,9079	0,7263	0,8070
0,80	0,9429	0,6947	0,8000
0,90	0,9688	0,6526	0,7799

Threshold optimal berdasarkan F1-Score: 0,75 dengan precision 0,9079, recall 0,7263, dan F1 0,8070.



Gambar 6: Grafik threshold vs metrik

6. Mengapa Accuracy Tidak Cukup?

Dataset ini memiliki rasio kelas 598,84 : 1. Model yang selalu memprediksi "Normal" akan mendapat accuracy 99,83%, tetapi tidak mendeteksi satu pun fraud. Ada tiga alasan accuracy tidak cukup:

1. Baseline sudah sangat tinggi secara gratis. Karena kelas mayoritas mendominasi, perubahan kecil pada prediksi fraud hampir tidak mengubah accuracy.

2. Accuracy memberi bobot setara ke kedua kelas. Padahal secara bisnis, false negative (fraud lolos) jauh lebih merugikan daripada false positive (transaksi normal salah dituduh fraud).
3. Accuracy tidak sensitif terhadap performa di kelas minoritas. Model bisa terlihat "bagus" padahal gagal total di kelas yang justru paling penting dideteksi.

7. Kesimpulan

1. Distribusi kelas sangat tidak seimbang (rasio 598,84 : 1), sehingga accuracy tidak layak dijadikan metrik utama.
2. SMOTE efektif meningkatkan kemampuan model mendeteksi fraud. Pada Random Forest, AUC-ROC naik dari 0,9559 → 0,9771. Pada Gradient Boosting, recall naik tajam ke 0,8421 — namun dengan konsekuensi precision yang jauh menurun.
3. Random Forest lebih stabil dibanding Gradient Boosting pada dataset ini, baik dengan maupun tanpa SMOTE. GB cenderung fluktuatif dan rentan menghasilkan false alarm berlebihan.
4. Rekomendasi model produksi: Random Forest + SMOTE dengan threshold tuning, karena memberikan keseimbangan terbaik antara performa, stabilitas, dan waktu training yang wajar.